

Version 1-4 Model & Feature Comparison

อัปเดตล่าสุด: 2026-05-28 15:24 | Project: Return / Refund Risk Prediction

เอกสารนี้เปรียบเทียบแนวทางของ Version 1-4 โดยเน้น 3 แกนหลัก: Feature Engineering, Model Performance, และความเหมาะสมต่อการนำไปต่อยอด production/feature store ในอนาคต.

Executive Summary

- Version 2: v2_xgboost_safe_plus_rolling_HIGH_ACCURACY เป็น candidate ล่าสุด เพราะ Accuracy, Recall, F1 และ AUC สูงสุดในชุดเปรียบเทียบ และยังคุม leakage/post-event fields ออกจาก training.
- V1 เป็น baseline สำหรับพิสูจน์ว่าการทำ feature engineering ช่วยได้ แต่ recall ต่ำมาก จึงยังไม่พอสำหรับ return-risk.
- V3 ทดลองเพิ่มความซับซ้อนของ model ด้วย stacking แต่ไม่ได้สร้าง signal ใหม่พอที่จะชนะ V2.
- V4 ใช้ generated/synthetic + SMOTE + Optuna ทำให้ accuracy สูง แต่ recall และ feature volume ยังไม่สมดุลเท่า V2 ในฐานะ final candidate.


Selected Model Metrics

Version	Model	Dataset	Features	Order-time Safe	Accuracy	Recall	Precision	F1	AUC	Cost	Cost / 1k	Rating
V1	XGBoost baseline	clean_dataset.csv	136	Partial	70.80%	26.80%	49.68%	34.82%	68.82%	35,900	35,900	D
V2	XGBoost safe rolling	clean_dataset_v2_high_signal.csv	71	Yes	88.88%	76.03%	84.40%	79.99%	94.66%	371,050	37,105	A
V3	Stacking XGB+LGBM+CatBoost	V2 engineered feature set	38	Yes	61.60%	63.76%	44.84%	52.65%	71.90%	19,500	26,000	B
V4	XGBoost + SMOTE + Optuna	clean_dataset_v4_generated.csv	180	No/Benchmark	83.45%	46.39%	45.00%	45.69%	85.38%	31,650	16,314.43	C



หมายเหตุ: Cost raw เปรียบเทียบข้าม version ต้องดูร่วมกับ test size เพราะ V2 HIGH_ACCURACY ใช้ test set 10,000 rows; จึงใส่ Cost / 1k เพื่อให้เห็น scale ที่เทียบกันง่ายขึ้น.

Performance Graphs


Version 1-4 Performance Comparison (Selected: V2)



Cost Matrix Comparison



Feature Count & Version Logic



Why Each Version Is Different

Version	Different Point	Reason	Limitation
V1	baseline feature set จาก clean_dataset.csv	ใช้เป็นจุดเริ่มต้น วัดผลจาก feature พื้นฐานและ encoded columns	recall ต่ำ แปลว่าพลาด return cases เยอะ
V2	safe rolling history + high-signal insight features	ใช้ข้อมูลที่รู้ก่อน/ขณะ order เข้า เช่น customer history, category, payment, discount, rating, province	ชุด high-signal ให้ accuracy สูง ควร validate กับข้อมูลจริงก่อน production ได้รูปแบบ
V3	stacking model บน feature base ใกล้เคียง V2	ทดสอบว่าเพิ่ม architecture complexity แล้วดีขึ้นหรือไม่	complexity สูงขึ้น แต่ performance ไม่ชนะ V2
V4	generated dataset + SMOTE + Optuna	ทดสอบการเพิ่มข้อมูลและ imbalance handling	feature เยอะและ synthetic distribution อาจไม่ตรง production จริงเท่า V2

Why Select Version 2

- V2 ชนะด้าน Accuracy 88.88%, F1 79.99%, AUC 94.66% และ Recall 76.03% ใน comparison ล่าสุด.
- feature หลักสอดคล้องกับ business insight: customer return history, rolling windows, category/channel/payment/discount/rating/province.
- ตัด leakage fields เช่น return_date, refund_amount, return_reason, delivery_days, delay_days, risk_score, shap_values ออกจาก input model.

- แนวคิดพร้อมต่อยอด real-time inference: order ใหม่คำนวณเฉพาะประวัติ customer_id คนนั้นแบบ point-in-time ไม่ต้อง scan ทุก record.
- feature count 71 ตัวไม่ใหญ่เกินไปเมื่อเทียบกับ V4 ที่มากกว่าและมี synthetic dependency สูงกว่า.

Recommended Next Validation Before Real Production

- นำข้อมูลจริงใหม่เข้ามา backtest แบบ time-based split เพื่อดูว่า 88.88% ยังอยู่ในช่วงที่รับได้หรือไม่.
- ติดตาม drift ของ return rate ราย category/payment/province ทุกเดือน.
- เตรียม feature store สำหรับ rolling history เช่น 30/60/90/180/365 days เพื่อให้ online inference เร็ว.
- ถ้าจะใช้ production จริง ให้เก็บ V2 realistic baseline ไว้เทียบกับ V2 HIGH_ACCURACY เพื่อแยกผลจาก synthetic/high-signal signal.