

Version 1 - Baseline XGBoost - Feature Engineering Process

เอกสารอธิบายกระบวนการสร้าง feature แบบอ่านเข้าใจง่าย พร้อม code/artifact ที่เกี่ยวข้อง

Process Overview

- อ่าน clean_dataset.csv เป็น source หลัก
- clean missing/outlier/duplicate จาก dataset ที่เตรียมไว้
- สร้าง feature พื้นฐาน เช่น order_hour, price/log price, customer/product/category fields และ encoded categorical columns
- drop target/post-event/identifier columns ก่อน train
- train XGBoost เป็น baseline เพื่อวัดว่าฟีเจอร์ชุดแรกให้ performance เท่าไร

Code / Artifact Reference

Code / Artifact	Path
feature_engineering.py	docs\version 1\feature_engineering.py
model_training.py	docs\version 1\model_training.py
model_evaluation.py	docs\version 1\model_evaluation.py

Input / Output

Stage	Artifact
Input clean data	data\processed\clean_dataset.csv
Engineered dataset	docs\version 1\data\features\df_engineered.csv
Used feature list	docs\version 1\data\features\train_test_sets.pkl

Feature Engineering Logic

- เริ่มจาก clean dataset ของ version นั้น แล้วสร้าง numeric/encoded/interaction features
- ใช้ train/test split เดียวใน version เพื่อเปรียบเทียบ model อย่างยุติธรรม
- drop leakage/identifier fields ก่อน train
- ประเมินด้วย Accuracy, Recall, Precision, F1, AUC และ Cost Matrix

Performance Result

Accuracy	Recall	Precision	F1	AUC	Cost	Rating	Used Features
70.80%	26.80%	49.68%	34.82%	68.82%	35,900	D	136

Decision

ใช้เป็น baseline เท่านั้น เพราะ recall ต่ำและพลาด return cases มาก

Important Notes

- เอกสารนี้ไม่ทับ model artifact เดิม แต่รีเจน documentation ให้ตรงกับสถานะล่าสุดของโปรเจกต์
- ถ้า metrics/model เปลี่ยน ให้รัน scripts/generate_current_project_docs_v1_to_v4.py ใหม่เพื่อ sync เอกสาร

- สำหรับ production จริงควร validate ด้วยข้อมูลจริงแบบ time-based holdout ก่อน deploy