

Version 2 - XGBoost Safe Plus Rolling HIGH_ACCURACY - Feature Engineering Process

เอกสารอธิบายกระบวนการสร้าง feature แบบอ่านเข้าใจง่าย พร้อม code/artifact ที่เกี่ยวข้อง

Process Overview

- ทำ EDA จาก clean_dataset_v2/high-signal เพื่อดู pattern: history, category, channel, payment, discount, rating, province
- สร้าง customer historical features แบบ point-in-time โดยไม่ใช้ order ปัจจุบันเป็นประวัติของตัวเอง
- เพิ่ม rolling windows 30/60/90/180/365 days เช่น cust_return_rate_30d, cust_order_count_90d, cust_spend_sum_180d
- เพิ่ม business interaction features เช่น category x payment, channel x category, discount band, rating band, province risk
- ตัด leakage/post-event fields และ identifier fields ก่อน train
- train XGBoost พร้อม threshold tuning เพื่อ balance Accuracy, Recall, F1, AUC และ Cost Matrix

Code / Artifact Reference

Code / Artifact	Path
feature_engineered_v2_HIGH_ACCURACY.py	docs\version 2\v2_xgboost_safe_plus_rolling_HIGH_ACCURACY\scripts\feature_engineered_v2_HIGH_ACCURACY.py
train_test_sets_v2_xgboost_safe_plus_rolling_HIGH_ACCURACY.pkl	docs\version 2\v2_xgboost_safe_plus_rolling_HIGH_ACCURACY\data\train_test_sets_v2_xgboost_safe_plus_rolling_HIGH_ACCURACY.pkl
best_model_v2_xgboost_safe_plus_rolling_HIGH_ACCURACY.pkl	docs\version 2\v2_xgboost_safe_plus_rolling_HIGH_ACCURACY\models\best_model_v2_xgboost_safe_plus_rolling_HIGH_ACCURACY.pkl

Input / Output

Stage	Artifact
Input clean data	docs\version 2\v2_xgboost_safe_plus_rolling_HIGH_ACCURACY\data\clean_dataset_v2_high_signal.csv
Engineered dataset	docs\version 2\v2_xgboost_safe_plus_rolling_HIGH_ACCURACY\data\df_engineered_v2_HIGH_ACCURACY.csv
Used feature list	docs\version 2\v2_xgboost_safe_plus_rolling_HIGH_ACCURACY\data\used_features_v2_xgboost_safe_plus_rolling_HIGH_ACCURACY.csv

Feature Engineering Logic

- Rolling history คำนวณย้อนหลังแบบ point-in-time: ใช้เฉพาะ order_date ก่อน order ปัจจุบันเท่านั้น
- ตัวอย่าง: ลูกค้ามี 2 order ก่อนหน้า, คืน 1 order, ไม่คืน 1 order => return_rate = 1 / 2 = 0.5 = 50%
- lookback windows: 30, 60, 90, 180, 365 days เพื่อให้ model เรียนรู้ว่าควรดูประวัติสั้น/กลาง/ยาวแค่ไหน
- ถ้าลูกค้าใหม่ไม่มีประวัติ จะ fill history count/rate/spend เป็น 0 เพื่อให้ predict ได้
- ตัด delivery_days และ delay_days เพราะเป็นข้อมูลหลังส่งสินค้า ไม่รู้ตอน order เพิ่งเข้า

Performance Result

Accuracy	Recall	Precision	F1	AUC	Cost	Rating	Used Features
88.88%	76.03%	84.40%	79.99%	94.66%	371,050	A	71

Decision

เลือกเป็น candidate หลัก เพราะ performance สูงสุดและ feature logic ตรงกับโจทย์ order-time prediction

Important Notes

- เอกสารนี้ไม่ทับ model artifact เดิม แต่รีเจน documentation ให้ตรงกับสถานะล่าสุดของโปรเจกต์
- ถ้า metrics/model เปลี่ยน ให้รัน scripts/generate_current_project_docs_v1_to_v4.py ใหม่เพื่อ sync เอกสาร
- สำหรับ production จริงควร validate ด้วยข้อมูลจริงแบบ time-based holdout ก่อน deploy