

จาก plot ที่ eda_province_risk.png
สังเกตได้ว่า ขนาด category นี้นั้น
เช่น ขนาด A, ขนาด B, ขนาด C
ค่ามันจะเปลี่ยนไป
เปลี่ยนขนาด A ค่าที่ออกมาเป็นยังไง

เช่น ข้อมูล 1 dimension Target = return
province vs return_rate 2 dimension Feature = อายุ, เพศ, ที่อยู่
ดูว่าอะไรที่มีผลกับ return_rate แล้วทำให้อายุ

เช่น การกระจาย (distribution) dimension = Target กับ Feature
หรือ province กับ Gender

vs return_rate ข้อมูลที่เราสนใจคือว่า Gender ว่าข้อมูลเพศที่มี return_rate สูงกว่าเพศชายก็ได้
อายุเพิ่มขึ้นขึ้นมา 2 ค่าก็ได้ สมมติค่าที่ได้กับค่าที่แรกกับค่าที่ได้มา มันไม่เหมือนกัน

ค่าที่จะมาทำ correlation ด้วยเป็น ตัวเลข ค่าที่เป็นข้อมูลสองตัว cross กันดูว่าค่าที่ได้มันจะเปลี่ยนไป

Features

region = ['Nonthaburi', 'Phuket', 'Bangkok', 'Chiang Mai', 'Songkhla', 'Khon Kaen', 'Chonburi',
'Remote Area']

ให้หาค่าข้อมูลด้วยว่า เอาค่า Aggregate มาด้วยเปล่า เช่น
โดยที่มีข้อมูล order ขึ้นมาอีก 3 เดือน ยกเว้น order นี้
ทำได้เปล่า

1 ปี 4 ไตรมาส ไตรมาส 1 = 3 เดือน

ดูเป็นรายไตรมาส หรือ รายเดือนขึ้นแล้วจะดูค่า order คนนั้น

ดูว่าแต่ละคน Group แบบไหนคือจะมา Group อีกที

การเก็บ feature ที่จำเป็น

ถ้าเราอยากจะได้รู้ว่าเราควรจะต้องดูข้อมูลของลูกค้าคนนั้น เราจะต้องประวัติเขาย้อนหลังไปกี่ปีแค่ไหน
เพื่อที่เราจะแบ่งส่วนนั้นว่าเขาแบ่งเป็น รายสัปดาห์ รายเดือน รายปี ดังนั้นเราต้องไปดูว่า Data
ของเรามีเป็นช่วงไว้อยู่กับข้อมูลของเรา ดังนั้น Group ของคนที่มัน Return กับลูกค้าคนนั้นหรือลูกค้า
รายคนแล้วดูว่า Return Date กับ Income เราย้อนกันขึ้นตามอะไรบ้าง ดูรายสัปดาห์ รายเดือน รายปี เราจะได้
รู้ว่าเราควรจะต้องดูเป็นรายสัปดาห์ รายเดือน หรือรายปี

checklist ระบุก่อนทำ Model

1. query เพื่อดึงข้อมูลใน feature มาทำทอย (ระบุสเกลก็ยังไม่เข้า คือ query ได้ทันที)
2. กำหนด Run Model เพื่อดู Accuracy % ของ Model + Validation test
ข้อมูล train + ข้อมูล test
3. ใกล้เคียงหรือ Low / Medium / High ดูว่าจะ cutoff ที่ไหน? เช่น < 30% Low, 30-60% Medium,
> 60% High

- ดูจาก Cost Matrix หรือจาก % return ใน EDA
- ดูว่าขนาดสินค้า cutoff เล็กเกินไปไหม?
- ไม่มีประวัติ cust_ratio = 0, days_since_last_return = -1
- ใช้จ่าย / ข้อมูลเฉลี่ย แทนประวัติลูกค้า / New Customer - มักมีต้นทุนต่ำ

ปรับแก้ + ทำเพิ่มเติม (เริ่มอธิบายต่อจาก Business Insight)

- สรุป Business Insight โดยนำเรื่องกราฟที่เราทำมาทั้งหมด 40 + ค่าชุดที่เราสนใจนำมาทำเป็นสรุป list ว่ามีอะไรบ้าง มี Insight อะไร เหตุผลที่เลือก ^{สรุป + ทำด้วย}
มีจุดสนใจในการทำในเรื่อง insight นี้ ข้อมูลเหล่านั้นประกอบที่เราทำให้เลือก feature นี้ (เวลา)
- ตอนที่เรารู้ list feature (เก่า) + list feature (ใหม่) $\rightarrow$ ที่สร้าง feature 30 +
ที่แบ่งมาแล้วก่อนจะนำเข้า train model การ cross check
ค่าที่ได้โดยสุ่มเลือกค่า Return ที่ถูกด้วยแล้ว Return Rate จะเท่าไร
โดยดูจากจำนวนกรณี | ทั้งหมด เช่น ต้น 4 ไม่มีต้น 4 ก็คือ 4 ใน 8 ส่วน $4/8 = 0.5$
- การทำ feature engineering โดยเราทำการ Compare Data Clean กับ ตัว list Feature โดยหลักการดูว่ามี feature ใหม่ว่าใช้ feature ใหม่ว่าที่ตัดทิ้ง เช่นอธิบาย และ ก็ทำเป็น version ไว้ดูด้วย เช่น โค้ดนี้เขาทำทำให้ได้ค่า Accuracy มากกว่าก็เก็บไว้ + ทำ version ใหม่ดูไปเรื่อย ๆ ว่าพอเราทำแล้วมันไหนดีกว่า ตอนทำอย่าลืม test Accuracy ด้วย (ดูว่าได้กี่เปอร์เซ็นต์) ทำแบบนี้สัก 5-6 ครั้ง ได้สัก 50% - 60% ก็โอเค

สมมติ version 1 ได้แบบนี้ ค่าแบบนี้ (ทำเป็น version ดูความแตกต่าง)

version 2 ได้แบบนี้ ค่าแบบนี้ (มันก็โอเคไว้ Backup กลับมาดู)

⋮
— — —

ตรงที่ feature ที่ใช้ตอนทำ model มันทำเท่าเดิมทบทวนว่า feature นั้นเราเก็บไว้
ว่าเพิ่ม - ลด feature เพื่อให้เห็นมันคือ query ได้เร็วขึ้น ณ resource ของระบบเรา
ข้อมูลมันเยอะ = จะทำให้ model ที่เคยใช้

- ทำ model ตามกันทำ feature เพื่อดูว่าประสิทธิภาพของ model มันดีขึ้นใน keyword หลักก็คือ การทำ feature ใหม่ - ลด + model + Business Insight

การคำนวณ ที่มี order ที่ 3 และข้อมูลก่อน ๆ อยู่ 2 order ถ้าเรามี order นี้
ที่ไม่ได้ขึ้น ทบทวนว่าเราเอาทุก order ที่ขึ้น ยกเว้น order ที่ไม่ได้ขึ้น
คิดเป็น : $1 \text{ ใน } 2 = 1/2 = 0.5$ แปลเป็น % = 50%

** ตอนที่ได้อะไรมาลองเอาเข้า excel แล้วเช็คค่าดูรวมกันว่าคำนวณถูกต้องมั๊ย

