

V1 Feature Engineering Process

Baseline feature engineering: สร้าง feature จำนวนมากและ encode จนได้ feature model 136 ตัว

Input / Output

Item	Path / Value
Input clean data	data\processed\clean_dataset.csv
Engineered dataset	docs\version 1\data\features\df_engineered.csv
Used feature count	136
Code files	docs\version 1\feature_engineering.py docs\version 1\model_training.py docs\version 1\model_evaluation.py

Feature Engineering Steps

1. Load clean_dataset.csv และเลือก field ที่เกี่ยวกับ order, customer, product, promotion, channel, payment และ history
2. สร้าง numeric/log features เช่น log_unit_price และ log_total_amount เพื่อลด skew ของราคาและยอดรวม
3. สร้าง binary flags เช่น is_peak_hour, is_cod, is_high_discount, is_first_order, low_rating_alert
4. สร้าง interaction features เช่น category_payment, category_channel, province_payment
5. สร้าง customer history features เช่น total_orders_before, total_returns_before, customer_return_ratio และ rolling history 30/60/180 วัน
6. Encode categorical variables และสร้าง train_test_sets.pkl
7. Train หลาย model แล้ว save best_model.pkl

Feature Groups Created / Used

Feature group	Count
product_category	41
customer_profile	32
payment_channel	30
customer_history	14
other	7
price_amount	5
time	4
promotion_discount	2
logistics	1

Reasoning

V1 ใช้เป็น baseline กว้าง ๆ เพื่อดูว่าการสร้าง feature จำนวนมากช่วย model ได้แค่ไหน แต่ recall ต่ำและ cost สูง จึงยังไม่ใช่ candidate หลัก

Model Result Snapshot

Metric	Value
Model	XGBClassifier
Accuracy	70.80%
Recall	26.80%
Precision	49.68%

Metric	Value
F1	34.82%
AUC	68.82%
Cost	35,900
Rating	D

Pseudo-code / Code Logic

```
df = read_csv("clean_dataset.csv")
df["log_unit_price"] = log1p(unit_price)
df["log_total_amount"] = log1p(total_amount)
df["is_cod"] = payment_method == "COD"
df["is_high_discount"] = total_discount_pct > 0.20
df["category_payment"] = category + "_" + payment_method
df["category_channel"] = category + "_" + channel_type
df = add_customer_history(df)
X = encode_and_scale(df.drop("is_returned"))
y = df["is_returned"]
train_test_sets = train_test_split(X, y, stratify=y, random_state=42)
```