

เอกสารเปรียบเทียบ Feature Engineering (Version 2)

เป้าหมายของ Version 2: ลดความซ้ำซ้อนและมิติของข้อมูล (Dimensionality Reduction) จาก 136 คอลัมน์ เหลือ 38 คอลัมน์ โดยใช้วิธี Target Encoding เพื่อดึงค่าสถิติความเสี่ยงมาใช้แทน One-Hot Encoding รวมถึงการสร้าง Smart Features ใหม่ ๆ เพื่อเพิ่มประสิทธิภาพการเรียนรู้ของโมเดล

1. ตัวแปรที่ถูกตัดทิ้ง (Dropped Features)

กลุ่มข้อมูลเหล่านี้ถูกคัดกรองออกเนื่องจาก 3 เหตุผลหลัก คือ 1) ข้อมูลระบุตัวตนที่ไม่ช่วยในการทำนาย 2) ข้อมูลหลังจากการสั่งซื้อที่ก่อให้เกิด Data Leakage และ 3) ข้อมูลที่เกี่ยวกับระบบเก่า

ชื่อ Feature	เหตุผลที่ตัดทิ้ง (Drop Logic)
order_id, customer_id, product_id, supplier_id, courier_id	เป็นรหัส ID (Identifier) ที่เป็นตัวเลขสุ่ม ไม่มีความหมายเชิงสถิติ
customer_name, customer_phone, product_name, supplier_name, supplier_contact	ข้อมูลส่วนบุคคลและข้อมูลตัวหนังสือ (Text) ที่ไม่จำเป็นต่อโครงสร้างโมเดล
expected_delivery_date, delivery_date	วันเวลาในอนาคต ทำให้เกิดข้อมูลรั่วไหล (Data Leakage) เพราะตอนที่ลูกค้ากดสั่งซื้อ เรายังไม่รู้วันส่งของจริง
return_id, return_date, return_reason, return_scenario, item_condition, return_status, refund_amount	ข้อมูลที่เป็นผลลัพธ์ของการคืนสินค้า (Leakage) ซึ่งจะรู้ก็ต่อเมื่อลูกค้าคืนของแล้วเท่านั้น
score_id, risk_score, risk_tier, scored_at, shap_values	ข้อมูลการทำนายจากระบบเก่า (System Artifacts) ไม่สามารถนำมาตั้งต้นทำนายใหม่ได้

2. ตัวแปรที่ถูกสร้างขึ้นใหม่ (Engineered Smart Features)

การสกัดข้อมูล (Feature Extraction) เพื่อให้ตัวแปรสื่อความหมายทางธุรกิจมากขึ้น

ชื่อ Feature ใหม่	ที่มาและประโยชน์ทางธุรกิจ
customer_tenure_months	คำนวณจาก (วันสั่งซื้อ - วันสมัครสมาชิก) เพื่อดูว่า "อายุการเป็นสมาชิก" ส่งผลต่อการทิ้งของหรือไม่ (ลูกค้าใหม่มักทิ้งของมากกว่าลูกค้าเก่า)
order_month, order_dayofweek, is_weekend	สกัดออกมาจาก order_date เพื่อดูความสัมพันธ์ของการสั่งซื้อในวันหยุด หรือ ช่วงปลายเดือน
age_group	จัดกลุ่มอายุลูกค้า (Binning) ออกเป็นช่วง เช่น <20, 20-30, 30-40 เพื่อให้โมเดล จับรูปแบบพฤติกรรมคนแต่ละเจนเนอเรชันได้ง่ายกว่าการใช้อายุแบบตัวเลขเดี่ยวๆ
logistics_risk	สูตร: damage_rate * is_fragile นำอัตราการทำของพังของขนส่ง มาคูณกับ ความเปราะบางของสินค้า เป็นดัชนีชี้วัดความเสี่ยงพัสดุพัง

3. การแปลงตัวแปรหมวดหมู่ด้วย Target Encoding (ความลับที่ทำให้ V2 แม่นขึ้น)

แทนที่จะใช้ One-Hot Encoding ซึ่งสร้างคอลัมน์ขยะจำนวนมหาศาล V2 เปลี่ยนมาใช้ **Target Encoding (Mean Encoding)** คือการเปลี่ยน "ชื่อหมวดหมู่" ให้เป็น "เปอร์เซ็นต์อัตราการคืนของของหมวดหมู่นั้นๆ" โดยตรง พร้อมใส่สมการ Smoothing ป้องกัน Overfitting

ตัวแปรที่ใช้ Target Encode	กลไกการทำงาน
province	เปลี่ยนชื่อจังหวัด เช่น "กรุงเทพ" เป็น อัตราตีกลับเฉลี่ยของคนทม. (เช่น 0.22) โมเดลจะรู้ทันทีว่าจังหวัดนี้เสี่ยงน้อยหรือมาก
brand, category	เปลี่ยนเป็นค่าความเสี่ยงของสินค้านั้นๆ (เช่น เสื้อผ้ามักโดนตีกลับสูงกว่าเครื่องใช้ไฟฟ้า)
payment_method, channel_type, courier_name, courier_type	แปลงวิธีจ่ายเงินขนส่ง และช่องทาง ให้เป็นตัวเลขความเสี่ยง
gender, membership_tier, promo_name, promo_type, age_group	แปลงหมวดหมู่ข้อมูลลูกค้าและโปรโมชั่นให้เป็นคะแนนความเสี่ยงเชิงพฤติกรรม

4. ตัวแปรที่เก็บไว้ใช้งานตามเดิม (Kept Features)

ตัวแปรประเภทตัวเลข (Numeric) ที่สามารถนำมาใช้งานได้เลย จะถูกเก็บไว้และนำไปทำ Scaling (ปรับสเกล) เพื่อป้อนเข้าโมเดล

รายการตัวแปรตัวเลขที่ถูกเก็บรักษาไว้
quantity, unit_price, tier_discount_pct, campaign_discount_pct, total_discount_pct, discount_applied_amount, total_amount (กลุ่มข้อมูลการเงิน/จำนวน)
delivery_time_expected_days, delivery_days, delay_days (กลุ่มข้อมูลประเมินระยะเวลาจัดส่ง)
is_repurchased_item, order_hour, days_since_last_order, hist_order_count, hist_return_rate (กลุ่มข้อมูลประวัติพฤติกรรมและ Interaction)
age (เมื่อนำไปทำอายุกลุ่มแล้ว แต่ยังคงเก็บตัวเลขอายุไว้ด้วย), damage_rate

สรุปผลกระทบต่อสถาปัตยกรรมข้อมูล (Data Architecture Impact)

จากการตัดตัวแปรที่ไม่ได้ใช้ (Drop) สร้างตัวแปรใหม่ (Engineer) และยุบรวมด้วย Target Encoding ทำให้จำนวนมิติข้อมูล (Dimensionality) เปลี่ยนแปลงดังนี้:

- **Version 1:** 136 คอลัมน์ (มีสัญญาณรบกวนเยอะ โมเดลลง)
- **Version 2:** 38 คอลัมน์ (มีแต่ตัวแปรเชิงสถิติที่เข้มข้น โมเดลเรียนรู้ได้แม่นยำขึ้นมาก)