

V2 Feature Comparison: clean_dataset.csv vs df_engineered.csv

เอกสารนี้สรุป feature ของ Version 2 สำหรับ model v2_xgboost_safe_plus_rolling ว่าเริ่มจาก clean_dataset.csv แล้วแปลงเป็น df_engineered.csv อย่างไร feature ไหนใช้เข้า model และ feature ไหนตัดทิ้งหรือไม่ใช้

1. Summary

Item	Value
Model	v2_xgboost_safe_plus_rolling / XGBoost
Source clean data	data\processed\clean_dataset.csv
V2 df_engineered output	docs\version 2\data\features\df_engineered.csv
Clean dataset columns	65
df_engineered columns	61
Model input features	60
Dropped / not used rows in audit	36
Post-event/leakage fields dropped	delay_days, delivery_date, delivery_days, item_condition, refund_amount, return_date, return_id, return_reason, return_scenario, return_status, risk_score, risk_tier, score_id, scored_at, shap_values

2. Feature Engineering Concept

- V2 selected ใช้แนวคิด order-time safe: ใช้เฉพาะข้อมูลที่ได้ตอน order เข้ามา และไม่ใช้ข้อมูลอนาคตของ order นั้น
- ตัด delivery_days และ delay_days เพราะเป็นข้อมูลหลังส่งสินค้า
- เพิ่ม rolling customer history 30/60/90/180/365 วัน เช่น hist_return_rate_90d = return_count_90d / order_count_90d
- เพิ่ม interaction features เช่น category_payment, category_channel, province_payment เพื่อให้ model เห็น pattern แบบผสม
- ใช้ customer/product/payment/channel/logistics/promotion/order-time features รวม 60 ตัวเข้า XGBoost

3. Used Features

Feature	Group	Reason
gender	customer_profile	เป็น input feature ของ v2_xgboost_safe_plus_rolling
age	customer_profile	เป็น input feature ของ v2_xgboost_safe_plus_rolling
membership_tier	customer_profile	เป็น input feature ของ v2_xgboost_safe_plus_rolling
province	customer_profile	เป็น input feature ของ v2_xgboost_safe_plus_rolling
customer_age_days	customer_profile	เป็น input feature ของ v2_xgboost_safe_plus_rolling

Feature	Group	Reason
category	product_category	เป็น input feature ของ v2_xgboost_safe_plus_rolling
brand	product_category	เป็น input feature ของ v2_xgboost_safe_plus_rolling
product_rating	product_category	เป็น input feature ของ v2_xgboost_safe_plus_rolling
courier_name	logistics	เป็น input feature ของ v2_xgboost_safe_plus_rolling
courier_type	logistics	เป็น input feature ของ v2_xgboost_safe_plus_rolling
avg_delivery_days	logistics	เป็น input feature ของ v2_xgboost_safe_plus_rolling
damage_rate	logistics	เป็น input feature ของ v2_xgboost_safe_plus_rolling
promo_name	promotion_discount	เป็น input feature ของ v2_xgboost_safe_plus_rolling
promo_type	promotion_discount	เป็น input feature ของ v2_xgboost_safe_plus_rolling
promo_discount_rate	promotion_discount	เป็น input feature ของ v2_xgboost_safe_plus_rolling
channel_type	payment_channel	เป็น input feature ของ v2_xgboost_safe_plus_rolling
payment_method	payment_channel	เป็น input feature ของ v2_xgboost_safe_plus_rolling
quantity	price_amount	เป็น input feature ของ v2_xgboost_safe_plus_rolling
unit_price	price_amount	เป็น input feature ของ v2_xgboost_safe_plus_rolling
tier_discount_pct	promotion_discount	เป็น input feature ของ v2_xgboost_safe_plus_rolling
campaign_discount_pct	promotion_discount	เป็น input feature ของ v2_xgboost_safe_plus_rolling
total_discount_pct	promotion_discount	เป็น input feature ของ v2_xgboost_safe_plus_rolling
discount_applied_amount	promotion_discount	เป็น input feature ของ v2_xgboost_safe_plus_rolling
total_amount	price_amount	เป็น input feature ของ v2_xgboost_safe_plus_rolling
delivery_time_expected_days	logistics	เป็น input feature ของ v2_xgboost_safe_plus_rolling
is_repurchased_item	other	เป็น input feature ของ v2_xgboost_safe_plus_rolling
order_hour	time	เป็น input feature ของ v2_xgboost_safe_plus_rolling
days_since_last_order	customer_history	เป็น input feature ของ v2_xgboost_safe_plus_rolling
hist_order_count	customer_history	เป็น input feature ของ v2_xgboost_safe_plus_rolling
hist_return_rate	customer_history	เป็น input feature ของ v2_xgboost_safe_plus_rolling
customer_tenure_months	customer_profile	เป็น input feature ของ v2_xgboost_safe_plus_rolling
order_month	time	เป็น input feature ของ v2_xgboost_safe_plus_rolling
order_dayofweek	time	เป็น input feature ของ v2_xgboost_safe_plus_rolling
is_weekend	time	เป็น input feature ของ v2_xgboost_safe_plus_rolling
age_group	customer_profile	เป็น input feature ของ v2_xgboost_safe_plus_rolling

Feature	Group	Reason
logistics_risk	logistics	เป็น input feature ของ v2_xgboost_safe_plus_rolling
hist_order_count_30d	customer_history	เป็น input feature ของ v2_xgboost_safe_plus_rolling
hist_return_count_30d	customer_history	เป็น input feature ของ v2_xgboost_safe_plus_rolling
hist_return_rate_30d	customer_history	เป็น input feature ของ v2_xgboost_safe_plus_rolling
hist_spend_sum_30d	customer_history	เป็น input feature ของ v2_xgboost_safe_plus_rolling
hist_order_count_60d	customer_history	เป็น input feature ของ v2_xgboost_safe_plus_rolling
hist_return_count_60d	customer_history	เป็น input feature ของ v2_xgboost_safe_plus_rolling
hist_return_rate_60d	customer_history	เป็น input feature ของ v2_xgboost_safe_plus_rolling
hist_spend_sum_60d	customer_history	เป็น input feature ของ v2_xgboost_safe_plus_rolling
hist_order_count_90d	customer_history	เป็น input feature ของ v2_xgboost_safe_plus_rolling
hist_return_count_90d	customer_history	เป็น input feature ของ v2_xgboost_safe_plus_rolling
hist_return_rate_90d	customer_history	เป็น input feature ของ v2_xgboost_safe_plus_rolling
hist_spend_sum_90d	customer_history	เป็น input feature ของ v2_xgboost_safe_plus_rolling
hist_order_count_180d	customer_history	เป็น input feature ของ v2_xgboost_safe_plus_rolling
hist_return_count_180d	customer_history	เป็น input feature ของ v2_xgboost_safe_plus_rolling
hist_return_rate_180d	customer_history	เป็น input feature ของ v2_xgboost_safe_plus_rolling
hist_spend_sum_180d	customer_history	เป็น input feature ของ v2_xgboost_safe_plus_rolling
hist_order_count_365d	customer_history	เป็น input feature ของ v2_xgboost_safe_plus_rolling
hist_return_count_365d	customer_history	เป็น input feature ของ v2_xgboost_safe_plus_rolling
hist_return_rate_365d	customer_history	เป็น input feature ของ v2_xgboost_safe_plus_rolling
hist_spend_sum_365d	customer_history	เป็น input feature ของ v2_xgboost_safe_plus_rolling
discount_amount_ratio	promotion_discount	เป็น input feature ของ v2_xgboost_safe_plus_rolling
category_payment	product_category	เป็น input feature ของ v2_xgboost_safe_plus_rolling
category_channel	product_category	เป็น input feature ของ v2_xgboost_safe_plus_rolling
province_payment	payment_channel	เป็น input feature ของ v2_xgboost_safe_plus_rolling

4. Dropped / Not Used Features

ตารางนี้แสดง field จาก clean_dataset.csv และ intermediate V2 preview ที่ไม่ได้ใช้เข้า selected model พร้อมเหตุผล เช่น leakage, query-only หรือถูกแทนด้วย engineered feature

Source	Feature	Status	Reason	Group
clean_dataset.csv	order_id	query_or_audit_only	ใช้ join/query/audit ได้ แต่ไม่ส่งให้ model จำ identity โดยตรง	other
clean_dataset.csv	order_date	not_used_or_replaced	ไม่ได้ใช้ตรง หรือถูกแทนด้วย engineered feature อื่น	time
clean_dataset.csv	expected_delivery_date	not_used_or_replaced	ไม่ได้ใช้ตรง หรือถูกแทนด้วย engineered feature อื่น	logistics
clean_dataset.csv	delivery_date	dropped	เป็น post-event/leakage field จึงตัดออกเพื่อกันข้อมูลอนาคต	logistics
clean_dataset.csv	customer_id	query_or_audit_only	ใช้ join/query/audit ได้ แต่ไม่ส่งให้ model จำ identity โดยตรง	other
clean_dataset.csv	customer_name	query_or_audit_only	ใช้ join/query/audit ได้ แต่ไม่ส่งให้ model จำ identity โดยตรง	other
clean_dataset.csv	customer_phone	query_or_audit_only	ใช้ join/query/audit ได้ แต่ไม่ส่งให้ model จำ identity โดยตรง	other
clean_dataset.csv	preferred_channel	not_used_or_replaced	ไม่ได้ใช้ตรง หรือถูกแทนด้วย engineered feature อื่น	payment_channel
clean_dataset.csv	registration_date	not_used_or_replaced	ไม่ได้ใช้ตรง หรือถูกแทนด้วย engineered feature อื่น	time
clean_dataset.csv	product_id	query_or_audit_only	ใช้ join/query/audit ได้ แต่ไม่ส่งให้ model จำ identity โดยตรง	product_category
clean_dataset.csv	product_name	not_used_or_replaced	ไม่ได้ใช้ตรง หรือถูกแทนด้วย engineered feature อื่น	product_category
clean_dataset.csv	is_fragile	not_used_or_replaced	ไม่ได้ใช้ตรง หรือถูกแทนด้วย engineered feature อื่น	product_category
clean_dataset.csv	supplier_id	query_or_audit_only	ใช้ join/query/audit ได้ แต่ไม่ส่งให้ model จำ identity โดยตรง	other
clean_dataset.csv	supplier_name	not_used_or_replaced	ไม่ได้ใช้ตรง หรือถูกแทนด้วย engineered feature อื่น	other
clean_dataset.csv	supplier_contact	not_used_or_replaced	ไม่ได้ใช้ตรง หรือถูกแทนด้วย engineered feature อื่น	other
clean_dataset.csv	courier_id	query_or_audit_only	ใช้ join/query/audit ได้ แต่ไม่ส่งให้ model จำ identity โดยตรง	logistics
clean_dataset.csv	coverage_region	not_used_or_replaced	ไม่ได้ใช้ตรง หรือถูกแทนด้วย engineered feature อื่น	customer_profile
clean_dataset.csv	promo_id	query_or_audit_only	ใช้ join/query/audit ได้ แต่ไม่ส่งให้ model จำ identity โดยตรง	promotion_discount
clean_dataset.csv	promo_start_date	not_used_or_replaced	ไม่ได้ใช้ตรง หรือถูกแทนด้วย engineered feature อื่น	promotion_discount
clean_dataset.csv	promo_end_date	not_used_or_replaced	ไม่ได้ใช้ตรง หรือถูกแทนด้วย engineered feature อื่น	promotion_discount
clean_dataset.csv	delivery_days	dropped	เป็น post-event/leakage field จึงตัดออกเพื่อกันข้อมูลอนาคต	logistics

Source	Feature	Status	Reason	Group
clean_dataset.csv	delay_days	dropped	เป็น post-event/leakage field จึงตัดออกเพื่อกันข้อมูลอนาคต	logistics
clean_dataset.csv	return_id	dropped	เป็น post-event/leakage field จึงตัดออกเพื่อกันข้อมูลอนาคต	other
clean_dataset.csv	return_date	dropped	เป็น post-event/leakage field จึงตัดออกเพื่อกันข้อมูลอนาคต	time
clean_dataset.csv	return_reason	dropped	เป็น post-event/leakage field จึงตัดออกเพื่อกันข้อมูลอนาคต	other
clean_dataset.csv	return_scenario	dropped	เป็น post-event/leakage field จึงตัดออกเพื่อกันข้อมูลอนาคต	other
clean_dataset.csv	item_condition	dropped	เป็น post-event/leakage field จึงตัดออกเพื่อกันข้อมูลอนาคต	other
clean_dataset.csv	return_status	dropped	เป็น post-event/leakage field จึงตัดออกเพื่อกันข้อมูลอนาคต	other
clean_dataset.csv	refund_amount	dropped	เป็น post-event/leakage field จึงตัดออกเพื่อกันข้อมูลอนาคต	price_amount
clean_dataset.csv	score_id	dropped	เป็น post-event/leakage field จึงตัดออกเพื่อกันข้อมูลอนาคต	other
clean_dataset.csv	risk_score	dropped	เป็น post-event/leakage field จึงตัดออกเพื่อกันข้อมูลอนาคต	other
clean_dataset.csv	risk_tier	dropped	เป็น post-event/leakage field จึงตัดออกเพื่อกันข้อมูลอนาคต	other
clean_dataset.csv	scored_at	dropped	เป็น post-event/leakage field จึงตัดออกเพื่อกันข้อมูลอนาคต	other
clean_dataset.csv	shap_values	dropped	เป็น post-event/leakage field จึงตัดออกเพื่อกันข้อมูลอนาคต	other
df_engineered_v2_preview.csv	delivery_days	dropped_from_selected_v2	มีใน V2 preview แต่เป็น post-event/leakage field จึงตัดออกจาก selected model	logistics
df_engineered_v2_preview.csv	delay_days	dropped_from_selected_v2	มีใน V2 preview แต่เป็น post-event/leakage field จึงตัดออกจาก selected model	logistics

5. Clean Dataset Field Status

Clean Feature	Status	Reason
order_id	query_or_audit_only	ใช้ join/query/audit ได้ แต่ไม่ส่งให้ model จำ identity โดยตรง
order_date	not_used_or_replaced	ไม่ได้ใช้ตรง หรือถูกแทนด้วย engineered feature อื่น
expected_delivery_date	not_used_or_replaced	ไม่ได้ใช้ตรง หรือถูกแทนด้วย engineered feature อื่น
delivery_date	dropped	เป็น post-event/leakage field จึงตัดออกเพื่อกันข้อมูลอนาคต
customer_id	query_or_audit_only	ใช้ join/query/audit ได้ แต่ไม่ส่งให้ model จำ identity โดยตรง
customer_name	query_or_audit_only	ใช้ join/query/audit ได้ แต่ไม่ส่งให้ model จำ identity โดยตรง
customer_phone	query_or_audit_only	ใช้ join/query/audit ได้ แต่ไม่ส่งให้ model จำ identity โดยตรง
gender	used_exact	ใช้เข้า model โดยตรง
age	used_exact	ใช้เข้า model โดยตรง
membership_tier	used_exact	ใช้เข้า model โดยตรง
preferred_channel	not_used_or_replaced	ไม่ได้ใช้ตรง หรือถูกแทนด้วย engineered feature อื่น
province	used_exact	ใช้เข้า model โดยตรง
registration_date	not_used_or_replaced	ไม่ได้ใช้ตรง หรือถูกแทนด้วย engineered feature อื่น
customer_age_days	used_exact	ใช้เข้า model โดยตรง
product_id	query_or_audit_only	ใช้ join/query/audit ได้ แต่ไม่ส่งให้ model จำ identity โดยตรง
product_name	not_used_or_replaced	ไม่ได้ใช้ตรง หรือถูกแทนด้วย engineered feature อื่น
category	used_exact	ใช้เข้า model โดยตรง
brand	used_exact	ใช้เข้า model โดยตรง
is_fragile	not_used_or_replaced	ไม่ได้ใช้ตรง หรือถูกแทนด้วย engineered feature อื่น
product_rating	used_exact	ใช้เข้า model โดยตรง
supplier_id	query_or_audit_only	ใช้ join/query/audit ได้ แต่ไม่ส่งให้ model จำ identity โดยตรง
supplier_name	not_used_or_replaced	ไม่ได้ใช้ตรง หรือถูกแทนด้วย engineered feature อื่น
supplier_contact	not_used_or_replaced	ไม่ได้ใช้ตรง หรือถูกแทนด้วย engineered feature อื่น
courier_id	query_or_audit_only	ใช้ join/query/audit ได้ แต่ไม่ส่งให้ model จำ identity โดยตรง
courier_name	used_exact	ใช้เข้า model โดยตรง
courier_type	used_exact	ใช้เข้า model โดยตรง
avg_delivery_days	used_exact	ใช้เข้า model โดยตรง
damage_rate	used_exact	ใช้เข้า model โดยตรง
coverage_region	not_used_or_replaced	ไม่ได้ใช้ตรง หรือถูกแทนด้วย engineered feature อื่น

Clean Feature	Status	Reason
promo_id	query_or_audit_only	ใช้ join/query/audit ได้ แต่ไม่ส่งให้ model จำ identity โดยตรง
promo_name	used_exact	ใช้เข้า model โดยตรง
promo_type	used_exact	ใช้เข้า model โดยตรง
promo_discount_rate	used_exact	ใช้เข้า model โดยตรง
promo_start_date	not_used_or_replaced	ไม่ได้ใช้ตรง หรือถูกแทนด้วย engineered feature อื่น
promo_end_date	not_used_or_replaced	ไม่ได้ใช้ตรง หรือถูกแทนด้วย engineered feature อื่น
channel_type	used_exact	ใช้เข้า model โดยตรง
payment_method	used_exact	ใช้เข้า model โดยตรง
quantity	used_exact	ใช้เข้า model โดยตรง
unit_price	used_exact	ใช้เข้า model โดยตรง
tier_discount_pct	used_exact	ใช้เข้า model โดยตรง
campaign_discount_pct	used_exact	ใช้เข้า model โดยตรง
total_discount_pct	used_exact	ใช้เข้า model โดยตรง
discount_applied_amount	used_exact	ใช้เข้า model โดยตรง
total_amount	used_exact	ใช้เข้า model โดยตรง
delivery_time_expected_days	used_exact	ใช้เข้า model โดยตรง
delivery_days	dropped	เป็น post-event/leakage field จึงตัดออกเพื่อกันข้อมูลอนาคต
delay_days	dropped	เป็น post-event/leakage field จึงตัดออกเพื่อกันข้อมูลอนาคต
is_repurchased_item	used_exact	ใช้เข้า model โดยตรง
order_hour	used_exact	ใช้เข้า model โดยตรง
days_since_last_order	used_exact	ใช้เข้า model โดยตรง
hist_order_count	used_exact	ใช้เข้า model โดยตรง
hist_return_rate	used_exact	ใช้เข้า model โดยตรง
return_id	dropped	เป็น post-event/leakage field จึงตัดออกเพื่อกันข้อมูลอนาคต
return_date	dropped	เป็น post-event/leakage field จึงตัดออกเพื่อกันข้อมูลอนาคต
return_reason	dropped	เป็น post-event/leakage field จึงตัดออกเพื่อกันข้อมูลอนาคต
return_scenario	dropped	เป็น post-event/leakage field จึงตัดออกเพื่อกันข้อมูลอนาคต
item_condition	dropped	เป็น post-event/leakage field จึงตัดออกเพื่อกันข้อมูลอนาคต
return_status	dropped	เป็น post-event/leakage field จึงตัดออกเพื่อกันข้อมูลอนาคต
refund_amount	dropped	เป็น post-event/leakage field จึงตัดออกเพื่อกันข้อมูลอนาคต

Clean Feature	Status	Reason
score_id	dropped	เป็น post-event/leakage field จึงตัดออกเพื่อกันข้อมูลอนาคต
risk_score	dropped	เป็น post-event/leakage field จึงตัดออกเพื่อกันข้อมูลอนาคต
risk_tier	dropped	เป็น post-event/leakage field จึงตัดออกเพื่อกันข้อมูลอนาคต
scored_at	dropped	เป็น post-event/leakage field จึงตัดออกเพื่อกันข้อมูลอนาคต
shap_values	dropped	เป็น post-event/leakage field จึงตัดออกเพื่อกันข้อมูลอนาคต
is_returned	target	เป็น target label ไม่ใช่ input feature