

Version 4 - Generated Data + SMOTE + Optuna - Feature Engineering Process

เอกสารอธิบายกระบวนการสร้าง feature แบบอ่านเข้าใจง่าย พร้อม code/artifact ที่เกี่ยวข้อง

Process Overview

- generate synthetic order/return data เพื่อทดลองเพิ่มปริมาณข้อมูล
- clean missing/outlier/duplicate และสร้าง clean_dataset_v4_generated.csv
- ทำ EDA category/channel/payment/correlation
- สร้าง feature จำนวนมาก รวม interaction/encoded features
- ใช้ SMOTE สำหรับ imbalance และ Optuna สำหรับ tuning
- ประเมิน XGBoost/LightGBM/RandomForest/Logistic และเลือก XGBoost_SMOTE_Optuna

Code / Artifact Reference

Code / Artifact	Path
clean_dataset_v4.py	docs\version 4\scripts\clean_dataset_v4.py
run_v4_generated_end_to_end_pipeline.py	docs\version 4\scripts\run_v4_generated_end_to_end_pipeline.py

Input / Output

Stage	Artifact
Input clean data	docs\version 4\data\processed\clean_dataset_v4_generated.csv
Engineered dataset	docs\version 4\data\features\df_engineered_v4_generated.csv
Used feature list	docs\version 4\reports\model_evaluation\v4_used_features.csv

Feature Engineering Logic

- เริ่มจาก clean dataset ของ version นั้น แล้วสร้าง numeric/encoded/interaction features
- ใช้ train/test split เดียวใน version เพื่อเปรียบเทียบ model อย่างยุติธรรม
- drop leakage/identifier fields ก่อน train
- ประเมินด้วย Accuracy, Recall, Precision, F1, AUC และ Cost Matrix

Performance Result

Accuracy	Recall	Precision	F1	AUC	Cost	Rating	Used Features
83.45%	46.39%	45.00%	45.69%	85.38%	31,650	C	180

Decision

ใช้เป็น benchmark ของ generated data แต่ยังไม่เลือก final เพราะ V2 ให้ balance ดีกว่า

Important Notes

- เอกสารนี้ไม่ทับ model artifact เดิม แต่รีเจน documentation ให้ตรงกับสถานะล่าสุดของโปรเจกต์

- ถ้า metrics/model เปลี่ยน ให้รัน scripts/generate_current_project_docs_v1_to_v4.py ใหม่เพื่อ sync เอกสาร
- สำหรับ production จริงควร validate ด้วยข้อมูลจริงแบบ time-based holdout ก่อน deploy